

# Análise de Séries Temporais

## Modelos ARMA e ARIMA

Prof. Dr. José Augusto Fiorucci

Departamento de Estatística  
Universidade de Brasília

## Section 1

### Modelo Misto: ARMA

## Modelos Autoregressivos Médias Móveis (*autoregressive moving average*, ARMA(p,q))

- Def: Considere  $\{\varepsilon_t, t = 1, 2, \dots\}$  um ruído branco com média zero e variância  $\sigma^2$ . Um processo ARMA(p,q) é definido como sendo um processo **estacionário** do tipo

$$x_t = \phi_1 x_{t-1} + \dots + \phi_p x_{t-p} + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \dots + \theta_q \varepsilon_{t-q}$$

sendo  $\phi_1, \dots, \phi_p, \theta_1, \dots, \theta_q$  constantes.

- No caso do processo ter média  $\mu = E[x_t]$  diferente de zero, então o modelo pode ser aplicado para a série com média ajustada, isto é,

$$x_t - \mu = \phi_1 (x_{t-1} - \mu) + \dots + \phi_p (x_{t-p} - \mu) + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \dots + \theta_q \varepsilon_{t-q}$$

ou equivalentemente,

$$x_t = \alpha + \phi_1 x_{t-1} + \dots + \phi_p x_{t-p} + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \dots + \theta_q \varepsilon_{t-q}$$

em que  $\alpha = (1 - \phi_1 - \dots - \phi_p) \mu$  é o intercepto.

- No que segue, assumiremos sem perda de generalidade  $\mu = 0$ .

- Os modelos ARMA podem ser escrito em função dos operadores de retardo

$$\Phi_p(B) x_t = \Theta_q(B) \varepsilon_t$$

em que

$$\Phi_p(B) = 1 - \phi_1 B - \phi_2 B^2 - \dots - \phi_p B^p$$

é o *polinômio autoregressivo* e

$$\Theta_q(B) = 1 + \theta_1 B + \theta_2 B^2 + \dots + \theta_q B^q$$

é o *polinômio de média móvel*.

## Propriedades

Os Seguintes pontos devem ser destacados a respeito dos modelos ARMA(p,q)

- ❶ O processo é **estacionário** se as raízes de  $\Phi(B)$  estão fora do círculo unitário.
- ❷ O processo é **inversível** se as raízes de  $\Theta(B)$  estão fora do círculo unitário.
- ❸ O modelo ARMA(p,0) equivale ao AR(p) e o modelo ARMA(0,q) equivale ao MA(q).
- ❹ **Parcimonioso**, um modelo ARMA costuma requerer menos parâmetros que um modelo AR ou MA. Na maior parte das vezes um modelo ARMA(1,1) será suficiente para modelar uma séries estacionária.
- ❺ **Redundância na parametrização**, quando os polinômios  $\Phi(B)$  e  $\Theta(B)$  compartilham o mesmo fator, o modelo pode ser simplificado.
  - Por exemplo: o modelo ARMA(2,1) dado por
$$x_t = \frac{5}{6}x_{t-1} - \frac{1}{6}x_{t-2} + \varepsilon_t - \frac{1}{2}\varepsilon_{t-1}$$
 pode ser escrito como
$$(1 - \frac{5}{6}B + \frac{1}{6}B^2)x_t = (1 - \frac{1}{2}B)\varepsilon_t$$
, que por sua vez, pode ser escrito como
$$(1 - \frac{1}{2}B)(1 - \frac{1}{3}B)x_t = (1 - \frac{1}{2}B)\varepsilon_t$$
 e então podemos simplificar o termo em comum, resultando no modelo AR(1), dado por  $(1 - \frac{1}{3}B)x_t = \varepsilon_t$ .

## Propriedades

- Se verificada a condição de **estacionariedade**, um modelo ARMA(p,q) pode ser escrito como MA( $\infty$ )

$$x_t = \sum_{i=0}^{\infty} \psi_i \varepsilon_{t-i}$$

com  $\psi_0 = 1$ .

- Pode-se mostrar que os coeficientes são dados por

$$\psi_i = \theta_i + \sum_{j=1}^i \phi_j \psi_{i-j}, \quad j = 1, 2, 3, \dots$$

em que  $\psi_0 = 1$ ,  $\phi_j = 0$  para  $j > p$  e  $\theta_i = 0$  para  $i > q$ . A demonstração é semelhante ao que foi para os modelos AR na aula anterior (Brockwell & Davis, 1996).

- Essa representação do modelo é chamada de **forma causal** ou **forma de choques aleatórios**.

## Propriedades

- 7 Se verificada a condição de **inversibilidade**, um modelo ARMA(p,q) pode ser escrito como

$$x_t = \sum_{i=1}^{\infty} \varphi_i x_{t-i} + \varepsilon_t$$

- Essa representação do modelo é chamada de **forma inversível**
- 8 Se verificada as condições de **estacionariedade** e **inversibilidade**, podemos esperar que para um modelo ARMA(p,q)
  - FAC: decaia para zero de forma amortizada ou oscilando;
  - FACP: decaia para zero de forma amortizada ou oscilando;

## Resumo FAC e FACP

	FAC	FACP
AR(p)	decai para zero de forma amortizada ou oscilando	corte após lag p
MA(q)	corte após lag q	decai para zero de forma amortizada ou oscilando
ARMA(p,q)	decai para zero de forma amortizada ou oscilando	decai para zero de forma amortizada ou oscilando



## ARMA(1,1)

- Propriedades do modelo ARMA(1,1):

$$x_t = \phi x_{t-1} + \varepsilon_t + \theta \varepsilon_{t-1}$$

com  $|\phi| < 1$  (*estacionário*) e  $|\theta| < 1$  (*invertível*).

- Média

$$E[x_t] = 0$$

- Variância

$$\text{Var}[x_t] = \frac{1 + 2\phi\theta + \theta^2}{1 - \phi^2} \sigma^2$$

- Autocovariâncias

$$\gamma(1) = \frac{(\phi + \theta)(1 + \phi\theta)}{(1 - \phi^2)} \sigma^2$$

$$\gamma(h) = \phi \gamma(h-1), \quad h = 2, 3, 4, \dots$$

- Autocorrelações

$$\rho(1) = \frac{(\phi + \theta)(1 + \phi\theta)}{1 + 2\phi\theta + \theta^2}$$

$$\rho(h) = \phi \rho(h-1), \quad h = 2, 3, 4, \dots$$

## Section 2

# Modelo Misto Integrado: ARIMA

## Modelo ARMA Integrado (ARIMA)

- Modelos ARMA só podem ser aplicados para séries estacionárias. No entanto, a maior parte das séries não são estacionárias.
- Um modelo ARMA Integrado,  $ARIMA(p,d,q)$ , consiste em aplicar o modelo  $ARMA(p,q)$  na  $d$ -ésima diferença da série.
  - Seja  $\{x_t\}$  um processo não estacionário
  - Geralmente após algumas diferenças a série formada por  $w_t = \nabla^d x_t$  se torna estacionária
  - Assim, o modelo  $ARIMA(p,d,q)$  pode ser escrito como o modelo  $ARMA(p,q)$  aplicada a série  $\{w_t\}$ , isto é,

$$\Phi_p(B) w_t = \Theta_q(B) \varepsilon_t$$

- Lembrete:  $\nabla x_t = (1 - B)x_t$  e portanto  $w_t = \nabla^d x_t = (1 - B)^d x_t$
- O modelo  $ARIMA(p,d,q)$  pode ser escrito como

$$\Phi_p(B) (1 - B)^d x_t = \Theta_q(B) \varepsilon_t$$

## Modelo ARMA Integrado (ARIMA)

- Note que o modelo  $\text{ARIMA}(p,0,q)$  equivale ao modelo  $\text{ARMA}(p,q)$
- Frequentemente  $d = 1$  ou  $d = 2$  é suficiente para séries não sazonais (ou com sazonalidade ajustada)
- Um processo que se torna estacionário após “d” diferenças é chamado integrado de ordem d.

## Section 3

### Testes de estacionariedade

## Testes de estacionariedade

- Hipóteses usuais

$$\begin{cases} H_0 : \text{o processo é estacionário} \\ H_1 : \text{o processo possui raiz unitária ou} \\ \quad \text{possui tendência} \end{cases}$$

- Raiz unitária: processos em que o número 1 é raiz do polinômio autoregressivo.

- Exemplos:

- Passeio aleatório:  $x_t = x_{t-1} + \varepsilon_t$

$\Phi(B) = 1 - B \rightarrow B = 1$  é raiz, logo esse processo possui raiz unitária.

- ARIMA(p,d,q),  $d > 0$ :  $\Phi_p(B) (1 - B)^d x_t = \Theta_q(B) \varepsilon_t$

como  $B = 1$  é raiz de  $\Phi_p(B) (1 - B)^d$ , esse processo possui raiz unitária.

## Testes estatísticos para estacionariedade

- Teste KPSS

Kwiatkowski D, Phillips PCB, Schmidt P and Shin Y (1992), "Testing the Null Hypothesis of Stationarity against the Alternative of a Unit Root", Journal of Econometrics 54:159-178

- Teste de Phillips-Perron

Phillips, P.C.B. and Perron, P. (1988), "Testing for a unit root in time series regression", Biometrika, 72(2), 335-346.

- Teste ADF


Dickey DA and Fuller WA (1979), "Distribution of the Estimators for Autoregressive Time Series with a Unit Root", Journal of the American Statistical Association 74:427-431.

Obs 1: E testado a hipótese de que a série temporal é estacionária contra a hipótese de raiz unitária (tipo de série não estacionária, que será visto a frente).

Obs 2: Disponíveis no pacote *tseries* do R. Comandos: *kpss.test()*, *adf.test()*, *pp.test()*.

## Exemplo

```
x %>% plot(main='series original'); diff(x) %>% plot(main='série diferenciada');
```



```
kpss.test(x)
```

```
##
## KPSS Test for Level Stationarity
##
## data: x
## KPSS Level = 0.56549, Truncation lag parameter = 2, p-value = 0.02692
```

```
kpss.test(diff(x))
```

```
## Warning in kpss.test(diff(x)): p-value greater than printed p-value
```

```
##
## KPSS Test for Level Stationarity
##
## data: diff(x)
## KPSS Level = 0.15403, Truncation lag parameter = 2, p-value = 0.1
```



## Exemplo

- Função `ndiffs()` do pacote *forecast*: mostra o número de diferenças necessárias até a série se tornar estacionária.

```
x %>% ndiffs()
```

```
## [1] 1
```

```
diff(x) %>% ndiffs()
```

```
## [1] 0
```