

Análise de Séries Temporais

Estimação dos modelos ARMA e ARIMA

José Augusto Fiorucci

Section 1

Estimador de Mínimos Quadrados

Calculo dos erros

Dada uma série observada, digamos x_1, x_2, \dots, x_n , o termo de erro de um modelo ARMA ou ARIMA pode ser calculado recursivamente.

- Exemplo:

🔊 Modelo ARMA(1,1): $x_t = \phi x_{t-1} + \varepsilon_t + \theta \varepsilon_{t-1}$

logo, $\varepsilon_t = x_t - \phi x_{t-1} - \theta \varepsilon_{t-1}$

$$\varepsilon_1 = 0$$

$$\varepsilon_2 = x_2 - \phi x_1 - \theta \varepsilon_1$$

e portanto $\varepsilon_3 = x_3 - \phi x_2 - \theta \varepsilon_2$

$$\vdots$$

$$\varepsilon_n = x_n - \phi x_{n-1} - \theta \varepsilon_{n-1}$$

- Exemplo:

- 2) Modelo ARIMA(1,1,1):

Se $\{x_t\}$ é um processo ARIMA(1,1,1), então o processo formado por

$$w_t = \nabla x_t = x_t - x_{t-1}, \quad t = 2, 3, \dots, n$$

é ARMA(1,1). Desta forma,

$$w_t = \phi w_{t-1} + \varepsilon_t + \theta \varepsilon_{t-1}$$

e portanto

$$\varepsilon_1 = 0$$

$$\varepsilon_2 = 0$$

$$\varepsilon_3 = w_3 - \phi w_2 - \theta \varepsilon_2$$

$$\vdots$$

$$\varepsilon_n = w_n - \phi w_{n-1} - \theta \varepsilon_{n-1}$$

Soma do Erro Quadrático

Seja

$$\beta = (\phi_1, \dots, \phi_p, \theta_1, \dots, \theta_q)'$$

o vetor de parametros do modelo ARIMA(p,d,q) e

$$w_t = \nabla^d x_t$$

a série formada pelas diferenças de ordem d.

Assim a soma dos erros quadráticos pode ser escrita como

$$S(\beta) = \sum_{t=p+d+1}^n \varepsilon_t(\beta)^2$$

em que

$$\varepsilon_t(\beta) = x_t - \sum_{i=1}^p \phi_i w_{t-1} - \sum_{j=1}^q \theta_j \varepsilon_{t-j}, \quad t = p + d + 1, \dots, n$$

sendo $\varepsilon_1 = \varepsilon_2 = \dots = \varepsilon_{p+d} = 0$.

Assim o estimador de mínimos quadrados (EMQ) é definido como

$$\hat{\beta} = \operatorname{argmin}_{\beta} S(\beta)$$

OBS: Para a maior parte dos modelos da família ARIMA é impossível obter o EMQ de forma analítica e por conta disso, métodos numéricos geralmente são empregados.

Exercício

- Exercício: Mostre que para o modelo AR(1),

$$x_t = \phi x_{t-1} + \varepsilon_t$$

o EMQ de ϕ é dado por

$$\hat{\phi} = \frac{\sum_{t=2}^n x_t x_{t-1}}{\sum_{t=2}^n x_{t-1}^2}$$

Section 2

Estimador de máxima verossimilhança

Função de Verossimilhança

No que segue adotaremos a seguinte notação

- $x_{t|t-1}$ para representar a v.a. x_t condicionada em toda a informação prévia, no caso, $x_{t-1}, x_{t-2}, \dots, x_1$
- $\mu_{t|t-1} = E[x_{t|t-1}] = E_{t-1}[x_t] = E[x_t | x_{t-1}, x_{t-2}, \dots, x_1]$ para representar o valor esperado de $x_{t|t-1}$
- $\sigma_{t|t-1}^2 = Var[x_{t|t-1}] = Var_{t-1}[x_t] = Var[x_t | x_{t-1}, x_{t-2}, \dots, x_1]$ para representar a variância de $x_{t|t-1}$
- $f(x_{t|t-1}) = f_{t-1}(x_t) = f(x_t | x_{t-1}, x_{t-2}, \dots, x_1)$ para representar função densidade de probabilidade de $x_{t|t-1}$.

Função de Verossimilhança Condicional

- As variáveis x_1, \dots, x_n são geralmente condicionalmente dependentes, no entanto a função densidade de probabilidade conjunta pode ser escrita como

$$\begin{aligned} f(x_1, \dots, x_n) &= f(x_1)f(x_2|x_1)f(x_3|x_2, x_1) \dots f(x_n|x_{n-1}, x_{n-2}, \dots, x_1) \\ &= f(x_1) \prod_{t=2}^n f_{t-1}(x_t) \end{aligned}$$

- Se considerarmos que as primeiras k observações são necessárias apenas para inicializar o modelo, será útil escrever a equação anterior da seguinte forma

$$f(x_1, \dots, x_n) = f(x_1, \dots, x_k) \prod_{t=k+1}^n f_{t-1}(x_t)$$

- Como $f(x_1, \dots, x_k)$ é desconhecido, em séries temporais tradicionalmente utilizamos a função de verossimilhança condicional, definida como

$$L(\beta) = f(x_{k+1}, \dots, x_n | x_1, \dots, x_k) = \prod_{t=k+1}^n f_{t-1}(x_t)$$

em que β é vetor com todos os parâmetros do modelo.

Verossimilhança do modelo ARMA(p,q)

Considere o modelo ARMA(p,q), dado por

$$x_t = \phi_1 x_{t-1} + \cdots + \phi_p x_{t-p} + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \cdots + \theta_q \varepsilon_{t-q}$$

em que $\{\varepsilon_t\}$ é um processo i.i.d $N(0, \sigma^2)$

Note que

$$\mu_{t|t-1} = E_{t-1}[x_t] = \phi_1 x_{t-1} + \cdots + \phi_p x_{t-p} + \theta_1 \varepsilon_{t-1} + \cdots + \theta_q \varepsilon_{t-q}$$

$$\sigma_{t|t-1}^2 = \text{Var}_{t-1}[x_t] = \text{Var}[\varepsilon_t] = \sigma^2$$

Assim

$$x_{t|t-1} \sim N(\mu_{t|t-1}, \sigma^2)$$

e portanto,

$$\begin{aligned} L(\beta, \sigma^2) &= \prod_{t=p+1}^n f_{t-1}(x_t) = \prod_{t=p+1}^n (2\pi\sigma^2)^{-1/2} \exp\left\{-\frac{1}{2\sigma^2}(x_t - \mu_{t|t-1})^2\right\} \\ &= (2\pi\sigma^2)^{-(n-p-1)/2} \exp\left\{-\frac{1}{2\sigma^2}S(\beta)\right\} \end{aligned}$$

Verossimilhança do modelo ARMA(p,q)

Assim o logaritmo da função de verossimilhança condicional é dado por

$$\ell(\beta, \sigma^2) \propto \frac{-(n-p-1)}{2} \log(\sigma^2) + -\frac{1}{2\sigma^2} S(\beta)$$

Donde obtemos que o Estimador de Máxima Verossimilhança para σ^2 é dado por,

$$\hat{\sigma}^2 = \frac{S(\beta)}{n-p-1}$$

Agora, substituindo σ^2 por $\hat{\sigma}^2$ em $\ell(\beta, \sigma^2)$, obtemos

$$\ell(\beta) \propto \frac{-(n-p-1)}{2} \log(S(\beta))$$

Conclusão: *sob a hipótese de normalidade, o Estimador de Máxima Verossimilhança para β corresponde ao Estimador de Mínimos Quadrados.*

OBS 1: o resultado anterior pode ser estendido para qualquer modelo de espaço de estado linear, isto é, qualquer modelo que possa ser escrito no formato $x_t = g_t + \varepsilon_t$, em que g_t é uma função que depende apenas dos pontos anteriores ao tempo t .

OBS 2: em modelos $ARIMA(p,d,q)$ o procedimento de estimação consiste em primeiro calcular a série com d -diferenças, $w_t = \nabla^d x_t$, e então obter o EMV de $\{w_t\}$

OBS 3: se o processo estacionário $\{x_t\}$ possui média diferente de zero, isto é, $\mu = E[x_t] \neq 0$, então

$$\mu_{t|t-1} = \alpha + \phi_1 x_{t-1} + \cdots + \phi_p x_{t-p} + \theta_1 \varepsilon_{t-1} + \cdots + \theta_q \varepsilon_{t-q}$$

em que $\alpha = (1 - \phi_1 - \cdots - \phi_p)\mu$ é o intercepto.

OBS 4: em modelos $ARMA(1,1)$ (ou mesmo $ARIMA(1,d,1)$) desconfie de redundância na parametrização quando $\hat{\phi} \approx -\hat{\theta}$, pois nesta situação, $(1 - \hat{\phi})x_t = (1 + \hat{\theta})\varepsilon_t$ e portanto $x_t = \varepsilon_t$. Em ordens maiores, o problema de cancelamento de raízes é difícil de ser identificado, de modo que, deve-se sempre tentar usar modelos ordens mais baixas.