

Análise de Séries Temporais

Adequação dos modelos ARMA/ARIMA

José Augusto Fiorucci

Modelo ARMA(p,q)

$$x_t = \alpha + \phi_1 x_{t-1} + \cdots + \phi_p x_{t-p} + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \cdots + \theta_q \varepsilon_{t-q}$$

em que $\beta = (\alpha, \phi_1, \dots, \phi_p, \theta_1, \dots, \theta_q)'$ é o vetor de parâmetros e $\{\varepsilon_t\}$ é um ruído branco com média zero e variância σ^2 .

Equivalentemente, podemos escrever

$$x_t = \mu_{t|t-1} + \varepsilon_t$$

$$\mu_{t|t-1} = \alpha + \phi_1 x_{t-1} + \cdots + \phi_p x_{t-p} + \theta_1 \varepsilon_{t-1} + \cdots + \theta_q \varepsilon_{t-q}$$

Assim

$$\varepsilon_t = x_t - \mu_{t|t-1}$$

em que $\mu_{t|t-1}$ é função dos parâmetros, isto é, $\mu_{t|t-1} = \mu_{t|t-1}(\beta)$.



Logo se x_1, \dots, x_n é a série observada e $\hat{\beta}$ é a estimativa de β , então os resíduos do modelo são dados por

$$\varepsilon_t(\hat{\beta}) = x_t - \mu_{t|t-1}(\hat{\beta})$$



para $t = 1, \dots, n$.

- Suposições sobre $\{\varepsilon_t\}$
 - Média zero, $E[\varepsilon_t] = 0$, $t = 1, 2, 3, \dots$
 - Variância constante, $Var[\varepsilon_t] = \sigma^2$, $t = 1, 2, 3, \dots$
 - Covariância nula, $Cov[\varepsilon_t, \varepsilon_{t+h}] = 0$, $h \neq 0$, $t = 1, 2, 3, \dots$
 - “Normalidade”
 - Caso paramétrico
 - Especialmente importante em previsões intervalares (será visto a frente)
- De modo geral, o modelo estará bem ajustado se a série de resíduos satisfizer todas as hipóteses levantadas sobre $\{\varepsilon_t\}$.
 - Entre os modelos que atendem esses critérios, deve-se escolher o mais parcimonioso.



- Média







- Variância



- Autocovariância/Autocorrelação



- Aderência



- Estacionariedade

- Teste KPSS

Kwiatkowski D, Phillips PCB, Schmidt P and Shin Y (1992), "Testing the Null Hypothesis of Stationarity against the Alternative of a Unit Root", Journal of Econometrics 54:159-178

- Teste de Phillips-Perron

Phillips, P.C.B. and Perron, P. (1988), "Testing for a unit root in time series regression", Biometrika, 72(2), 335-346.

- Teste ADF

Dickey DA and Fuller WA (1979), "Distribution of the Estimators for Autoregressive Time Series with a Unit Root", Journal of the American Statistical Association 74:427-431.

Obs: Disponíveis no pacote *tseries* do R. Comandos: *kpss.test()*, *adf.test()*, *pp.test()*.

- Testes de independência:

- Hipóteses:

$$H_0 : \rho(1) = \rho(2) = \dots = \rho(m) = 0$$

$$H_1 : \text{pelo menos um diferente de zero}$$

- Teste de Box-Pierce (Box, G. E. P.; Pierce, D. A. (1970))

- Estatística:

$$Q = n \sum_{h=1}^m \widehat{\rho}(h)^2$$

em que $\widehat{\rho}(h)$ é a autocorrelação amostral com lag h .

- Sob H_0 , como $\sqrt{n}\widehat{\rho}(h) \sim^a N(0, 1)$, segue que $Q \sim^a \chi_m^2$. Portanto, com nível de significância α , rejeita-se H_0 se $Q > \chi_{m, 1-\alpha}^2$.

- Teste de Ljung-Box (Ljung, G. M. & Box, G. E. P. (1978))

- Estatística:

$$Q = n(n+2) \sum_{h=1}^m \widehat{\rho}(h)^2 / (n-h)$$

- Sob H_0 , pode-se mostrar que $Q \sim^a \chi_m^2$. Portanto, com nível de significância α , rejeita-se H_0 se $Q > \chi_{m, 1-\alpha}^2$.

- Testes de independência (continuação):
 - O teste de Ljung-Box é mais recente e apresenta melhores resultados, especialmente para séries com poucas observações;
 - Quando empregado nos resíduos dos modelos ARMA(p,q), as referências sugerem que utilizar $Q \sim \chi^2_{m-p-q}$ traz melhores resultados.
 - Neste caso, obviamente deve-se garantir que $m > p + q$.
 - Geralmente escolhe-se $m \approx 15$.
 - No R utilize `Box.test()` para ambos os testes.

- Testes de Aderência:
 - Normalidade
 - Teste de Shapiro-Wilk
 - No R: *shapiro.test()*
 - Outras distribuições
 - Teste de Kolmogorov-Smirnov
 - No R: *ks.test()*

- De modo geral, quando dois ou mais modelos da mesma família atendem todas as hipóteses é preferível escolher aquele com menos parâmetros
- Os critérios de parcimônia fazem um balanço entre a qualidade do ajuste e o grau de complexidade do modelo
 - Critério de informação de Akaike

$$AIC = 2k - 2\log(L(\hat{\beta}, \hat{\sigma}^2))$$

em que, k denota o número de parâmetros do modelo e $L(\hat{\beta}, \hat{\sigma}^2)$ a função de verossimilhança ajustada.

- AIC corrigido para pequenas amostras

$$AICc = AIC + (2k^2 + 2k)/(n - k - 1)$$

- em ambos os casos, deve-se escolher o modelo com menor valor do critério escolhido.