

# Análise de Séries Temporais

## Modelo ARIMA Sazonal (SARIMA)

José Augusto Fiorucci

- Seja “s” o número de observações por ciclo sazonal (geralmente anual).
  - Exemplo:
    - série mensal:  $s=12$
    - série bimestral:  $s=6$
    - série trimestral:  $s=4$
- Operador de diferenças sazonais ( $\nabla_s$ )

$$\nabla_s X_t = X_t - X_{t-s}$$

- Exemplo:
  - série mensal:  $\nabla_{12} X_t = X_t - X_{t-12}$
  - série bimestral:  $\nabla_6 X_t = X_t - X_{t-6}$
  - série trimestral:  $\nabla_4 X_t = X_t - X_{t-4}$
- No caso de ordens maiores, o operador é aplicado recursivamente.
  - Exemplo:  $\nabla_s^2 X_t = \nabla_s(\nabla_s X_t) = \nabla_s X_t - \nabla_s X_{t-s} = X_t - 2X_{t-s} + X_{t-2s}$
- Em termos do operador de retardo, note que

$$\nabla_s X_t = (1 - B^s) X_t$$

e portanto,

$$\nabla_s^D X_t = (1 - B^s)^D X_t$$

- **sAR(P)** - Sazonal Puro Autoregressivo de ordem P

$$x_t = \varphi_1 x_{t-s} + \varphi_2 x_{t-2s} + \cdots + \varphi_P x_{t-Ps} + \varepsilon_t$$

em que  $\varphi_1, \varphi_2, \dots, \varphi_P$  são os coeficientes autoregressivos sazonais.

Equivalentemente, podemos escrever

$$\Phi_P(B^s)x_t = \varepsilon_t$$

em que  $\Phi_P(B^s) = 1 - \varphi_1 B^s - \varphi_2 B^{2s} - \cdots - \varphi_P B^{Ps}$  é o polinômio autoregressivo sazonal.

- note que o modelo sAR(P) consiste basicamente em um modelo AR de ordem  $p = P \times s$ , em que os coeficientes não sazonais são assumidos como sendo zero.
- condição de estacionariedade: a mesma do modelo AR( $p = P \times s$ )

- **sMA(Q)** - Sazonal Puro Médias Moveis de ordem Q

$$x_t = \varepsilon_t + \vartheta_1 \varepsilon_{t-s} + \vartheta_2 \varepsilon_{t-2s} + \cdots + \vartheta_Q \varepsilon_{t-Qs}$$

em que  $\vartheta_1, \vartheta_2, \dots, \vartheta_Q$  são os coeficientes de médias móveis sazonais.

Equivalentemente, podemos escrever

$$x_t = \Theta_Q(B^s) \varepsilon_t$$

em que  $\Theta_Q(B^s) = 1 + \varphi_1 B^s + \varphi_2 B^{2s} + \cdots + \varphi_Q B^{Qs}$  é o polinômio de médias moveis sazonal.

- note que o modelo sMA(Q) consiste basicamente em um modelo MA de ordem  $q = Q \times s$ , em que os coeficientes não sazonais são assumidos como sendo zero.
- condição de estacionariedade: sempre estacionário
- condição de inversibilidade: a mesma do modelo MA( $q = Q \times s$ )

- **sARMA(P,D,Q)** - Sazonal Puro ARMA(P,Q)

$$\Phi_P(B^s) x_t = \Theta_Q(B^s) \varepsilon_t$$

- note que o modelo sARMA(P,Q) consiste basicamente em um modelo ARMA(p,q) de ordem  $p = P \times s$  e  $q = Q \times s$ , em que os coeficientes não sazonais são assumidos como sendo zero.
- condição de estacionariedade: a mesma do modelo AR( $p = P \times s$ )
- condição de inversibilidade: a mesma do modelo MA( $q = Q \times s$ )

- **sARIMA(P,Q)** - Sazonal Puro ARIMA(P,D,Q)

$$\Phi_P(B^s) \nabla_s^D x_t = \Theta_Q(B^s) \varepsilon_t$$

- note que  $w_t = \nabla_s^D x_t$  é um processo estacionário sARMA(P,Q).
- generaliza todos os modelos sazonais puros vistos.

- A mistura dos modelos *Sazonal Puros ARIMA* com os modelos *ARIMA não sazonais* da origem aos modelos conhecidos como *ARIMA Sazonal*, ou simplesmente, SARIMA.
- O modelo  $\text{SARIMA}(p,d,q) \times (P,D,Q)$  é definido como

$$\Phi_P(B^s) \Phi_p(B) \nabla_s^D \nabla^d x_t = \Theta_Q(B^s) \Theta_q(B) \varepsilon_t$$

- Generaliza todos os modelos da família ARIMA
- Permite modelar séries estacionárias e não estacionárias, bem como séries sazonais e não sazonais

- Exemplo 1: Se  $\{x_t\}$  segue um processo SARIMA(1,0,1) $\times$ (1,0,1), qual a função da média condicional e dos resíduos do modelo?

- Abrindo a equação do modelo

$$\begin{aligned}\Phi_1(B^s) \Phi_1(B) x_t &= \Theta_1(B^s) \Theta_1(B) \varepsilon_t \\ \Rightarrow (1 - \varphi B^s)(1 - \phi B) x_t &= (1 + \vartheta B^s)(1 + \theta B) \varepsilon_t \\ \Rightarrow (1 - \phi B - \varphi B^s + \phi \varphi B^{s+1}) x_t &= (1 + \theta B + \vartheta B^s + \theta \vartheta B^{s+1}) \varepsilon_t \\ \Rightarrow x_t - \phi x_{t-1} - \varphi x_{t-s} + \phi \varphi x_{t-s-1} &= \varepsilon_t + \theta \varepsilon_{t-1} + \vartheta \varepsilon_{t-s} + \theta \vartheta \varepsilon_{t-s-1} \\ \Rightarrow x_t = \phi x_{t-1} + \varphi x_{t-s} - \phi \varphi x_{t-s-1} + \varepsilon_t + \theta \varepsilon_{t-1} + \vartheta \varepsilon_{t-s} + \theta \vartheta \varepsilon_{t-s-1}\end{aligned}$$

- Portanto, a média condicional é dada por

$$\mu_{t|t-1} = \phi x_{t-1} + \varphi x_{t-s} - \phi \varphi x_{t-s-1} + \theta \varepsilon_{t-1} + \vartheta \varepsilon_{t-s} + \theta \vartheta \varepsilon_{t-s-1}$$

- Se  $\hat{\beta}$  é a estimativa do vetor de parâmetros, então os resíduos são dados por

$$\varepsilon_t(\hat{\beta}) = x_t - \mu_{t|t-1}(\hat{\beta}), \quad t = s+2, \dots, n$$

- Obs: Para inicializar o modelo, geralmente é tomado  $\varepsilon_1 = \dots = \varepsilon_{s+1} = 0$ , ficando assim perdidos os erros do primeiro ciclo sazonal. Desta forma  $\mu_{t|t-1}$  pode ser calculado no intervalo  $s+1 < t \leq n+1$ .

- Exemplo 2: Repita o exemplo 1 para o modelo  $\text{SARIMA}(1,1,1) \times (1,1,1)$ .

- Modelo

$$\Phi_1(B^s) \Phi_1(B) \nabla_s \nabla x_t = \Theta_1(B^s) \Theta_1(B) \varepsilon_t$$

- Série estacionária

$$w_t = \nabla_s \nabla x_t = \nabla_s (x_t - x_{t-1}) = x_t - x_{t-s} - x_{t-1} + x_{t-s-1}, \quad t > s + 1$$

- Sabemos que  $\{w_t\}$  é  $\text{SARIMA}(1,0,1) \times (1,0,1)$ . Do exemplo 1, temos que a média condicional do  $w_t|_{t-1}$  é dada por

$$\mu_{t|t-1}^{(w)} = \phi w_{t-1} + \varphi w_{t-s} - \phi \varphi w_{t-s-1} + \theta \varepsilon_{t-1} + \vartheta \varepsilon_{t-s} + \theta \vartheta \varepsilon_{t-s-1}, \quad t = 2s+3, \dots, n$$

e portanto os resíduos do modelo

$$\varepsilon_t(\hat{\beta}) = w_t - \mu_{t|t-1}^{(w)}(\hat{\beta}), \quad t = 2s + 3, \dots, n$$

- Das equações anteriores, segue que a média condicional do  $x_t$  é dada por

$$\begin{aligned} \mu_{t|t-1} &= E_{t-1}[x_t] \\ &= E_{t-1}[w_t + x_{t-s} + x_{t-1} - x_{t-s-1}] \\ &= E_{t-1}[w_t] + x_{t-s} + x_{t-1} - x_{t-s-1} \\ &= \mu_{t|t-1}^{(w)} + x_{t-s} + x_{t-1} - x_{t-s-1} \end{aligned}$$

assim  $\mu_{t|t-1}$  pode ser calculado recursivamente para  $t = 2s + 3, \dots, n$ .

- Note que pelo menos dois ciclos sazonais são perdidos na inicialização do modelo, o que pode inviabilizar aplicações em séries com poucas observações.



- Def.: Um processo  $\{x_t\}$  tem *raiz unitária sazonal* se o número 1 é raiz do polinômio autoregressivo sazonal.
  - Assim como os processos de raiz unitária vistos na Aula 7, processos com raiz unitária sazonal são não estacionários.
  - Exemplo: Considere o processo sazonal definido como  $x_t = x_{t-s} + \varepsilon_t$ 
    - Note que o processo pode ser escrito como  $(1 - B^s)x_t = \varepsilon_t$ , e portanto,  $B = 1$  é raiz do polinômio autoregressivo sazonal, dado por,  $\Phi(B^s) = 1 - B^s$ .
    - Logo, esse processo é não estacionário.
- Obs: qualquer processo  $SARIMA(p, d, q) \times (P, D, Q)$  em que  $d \geq 1$  ou  $D \geq 1$ , é não estacionário.
  - Note que o processo do exemplo anterior consiste em um  $SARIMA(0, 0, 0) \times (0, 1, 0)$
- Exercício: para o processo

$$x_t = 0.5x_{t-1} + x_{t-s} - 0.5x_{t-s-1} + \varepsilon_t - 0.3\varepsilon_{t-1}$$

identifique a ordem do SARIMA correspondente e verifique se é estacionário.

A função `nsdiffs()` do pacote *forecast* verifica quantas diferenças sazonais são necessárias para tornar a série estacionária, baseado em um dos testes de raiz unitária sazonal, listados abaixo:

- ① Wang, X, Smith, KA, Hyndman, RJ (2006) "Characteristic-based clustering for time series data", *Data Mining and Knowledge Discovery*, 13(3), 335-364.
- ② Osborn DR, Chui APL, Smith J, and Birchenhall CR (1988) "Seasonality and the order of integration for consumption", *Oxford Bulletin of Economics and Statistics* 50(4):361-377.
  - função: `forecast::ocsb.test()`
- ③ Canova F and Hansen BE (1995) "Are Seasonal Patterns Constant over Time? A Test for Seasonal Stability", *Journal of Business and Economic Statistics* 13(3):237-252.
  - função: `uroot::ch.test()`
- ④ Hylleberg S, Engle R, Granger C and Yoo B (1990) "Seasonal integration and cointegration.", *Journal of Econometrics* 44(1), pp. 215-238.
  - função: `uroot::hegy.test()`

Obs: de modo geral, se for necessário utilizar diferenças sazonais, então  $D = 1$  será suficiente para a grande maioria das séries.