

# Análise de Séries Temporais

## Previsão utilizando modelos ARIMA

José Augusto Fiorucci

## Section 1

# Previsão em Séries Temporais

## Introdução

Def.: Dado uma série temporal  $x_1, \dots, x_n$ , definimos a previsão para  $x_{n+h}$  ( $h$ -passos a frente), com  $h \geq 1$ , de duas maneiras:

- **Previsão pontual:** o valor esperado condicional de  $x_{n+h}$ , isto é,

$$\hat{x}_{n+h|n} = \mu_{n+h|n} = E[x_{n+h}|x_n, x_{n-1}, \dots, x_1]$$

- Obs: a variância condicional, dada por

$$\sigma_{n+h|n}^2 = \text{Var}[x_{n+h}|x_n, x_{n-1}, \dots, x_1] = E[(x_{n+h} - \mu_{n+h|n})^2|x_n, x_{n-1}, \dots, x_1]$$

é chamada de *erro quadrático médio de previsão*.

- **Previsão intervalar:** dado uma probabilidade de cobertura,  $100(1 - \alpha)\%$ , a previsão intervalar consiste no intervalo  $(LI, LS)$ , tal que,

$$1 - \alpha = P[LI < x_{n+h} < LS|x_n, x_{n-1}, \dots, x_1]$$

- Note que, se  $x_{n+h|n} \sim N(\mu_{n+h|n}, \sigma_{n+h|n}^2)$ , então

$$LI = \mu_{n+h|n} - Z_{(1-\alpha/2)} \sqrt{\sigma_{n+h|n}^2}$$

$$LS = \mu_{n+h|n} + Z_{(1-\alpha/2)} \sqrt{\sigma_{n+h|n}^2}$$

em que  $Z_{(p)}$  denota o quantil  $p$  da Normal padrão.

Obs: o lag de previsão  $h$  é chamado de **horizonte de previsão**.

# Introdução

- Em muitos modelos  $\mu_{n+h|n}, \sigma_{n+h|n}^2$  ou mesmo a distribuição de probabilidade de  $x_{n+h|n}$  é difícil de ser obtido analiticamente. Nestes casos, geralmente métodos numéricos são empregados.

## Section 2

### Previsão em modelos ARMA

## Previsão em modelos MA(q)

Modelo MA(q),

$$x_t = \varepsilon_t + \theta_1 \varepsilon_{t-1} + \cdots + \theta_q \varepsilon_{t-q},$$

em que  $\{\varepsilon_t\}$  é um processo i.i.d com média zero e variância  $\sigma_\varepsilon^2$

Após o ajuste do modelo, os resíduos  $\varepsilon_1, \dots, \varepsilon_n$  são conhecidos. Então:

- 1-passo: como  $x_{n+1} = \varepsilon_{n+1} + \theta_1 \varepsilon_n + \cdots + \theta_q \varepsilon_{n-q+1}$ , segue que
  - $\mu_{n+1|n} = E_n[x_{n+1}] = \theta_1 \varepsilon_n + \cdots + \theta_q \varepsilon_{n-q+1}$
  - $\sigma_{n+1|n}^2 = \text{Var}_n[x_{n+1}] = \text{Var}[\varepsilon_{n+1}] = \sigma_\varepsilon^2$
- 2-passos: como  $x_{n+2} = \varepsilon_{n+2} + \theta_1 \varepsilon_{n+1} + \theta_2 \varepsilon_n + \cdots + \theta_q \varepsilon_{n-q+2}$ , segue que
  - $\mu_{n+2|n} = E_n[x_{n+2}] = \theta_2 \varepsilon_n + \cdots + \theta_q \varepsilon_{n-q+2}$
  - $\sigma_{n+2|n}^2 = \text{Var}_n[x_{n+2}] = \text{Var}[\varepsilon_{n+2} + \theta_1 \varepsilon_{n+1}] = (1 + \theta_1^2) \sigma_\varepsilon^2$
- $\vdots$
- h-passos:  $x_{n+h} = \varepsilon_{n+h} + \theta_1 \varepsilon_{n+h-1} + \theta_2 \varepsilon_{n+h-2} + \cdots + \theta_q \varepsilon_{n-q+h}$ 
  - $\mu_{n+h|n} = \begin{cases} \theta_h \varepsilon_n + \cdots + \theta_q \varepsilon_{n-q+h}, & h \leq q \\ 0, & h > q \end{cases}$
  - $\sigma_{n+h|n}^2 = \left(1 + \sum_{j=1}^{\min(h-1, q)} \theta_j^2\right) \sigma_\varepsilon^2$

- Segue da equação anterior que o erro quadrático de previsão em um modelo  $MA(\infty)$  é dado por

$$\sigma_{n+h|n}^2 = \left( 1 + \sum_{j=1}^{h-1} \theta_j^2 \right) \sigma_\varepsilon^2$$

- Uma vez que qualquer modelo estacionário,  $AR(p)$  ou  $ARMA(p,q)$ , pode ser escrito como um  $MA(\infty)$ , a equação anterior pode ser utilizada para calcular o erro quadrático de previsão desses modelos.

# Previsão em Modelos ARMA

## Modelo ARMA(1,1)

$$x_t = \phi x_{t-1} + \varepsilon_t + \theta \varepsilon_{t-1}$$

- 1-passo: como  $x_{n+1} = \phi x_n + \varepsilon_{n+1} + \theta \varepsilon_n$ , segue que

- $\mu_{n+1|n} = E_n[x_{n+1}] = \phi x_n + \theta \varepsilon_n$

- $\sigma_{n+1|n}^2 = \text{Var}_n[x_{n+1}] = \text{Var}[\varepsilon_{n+1}] = \sigma_\varepsilon^2$

- 2-passos: como  $x_{n+2} = \phi x_{n+1} + \varepsilon_{n+2} + \theta \varepsilon_{n+1}$ , segue que

- $\mu_{n+2|n} = E_n[x_{n+2}] = \phi E_n[x_{n+1}] = \phi \mu_{n+1|n}$

- $\sigma_{n+2|n}^2 = \text{Var}_n[x_{n+2}] = \text{Var}_n[\phi x_{n+1} + \varepsilon_{n+2} + \theta \varepsilon_{n+1}]$

- $= \phi^2 \text{Var}_n[x_{n+1}] + \text{Var}[\varepsilon_{n+2}] + \theta^2 \text{Var}[\varepsilon_{n+1}] + \phi \theta \text{cov}_n(x_{n+1}, \varepsilon_{n+1})$
  - $\vdots$
  - $\vdots$
  - $= \phi^2 \sigma_{n+1|n}^2 + (1 + \theta^2 + \phi \theta) \sigma_\varepsilon^2$

- h-passos:  $x_{n+h} = \phi x_{n+h-1} + \varepsilon_{n+h} + \theta \varepsilon_{n+h-1}$

- $\mu_{n+h|n} = E_n[x_{n+h}] = \phi \mu_{n+h-1|n}$

- $\sigma_{n+h|n}^2 = \phi^2 \text{Var}_n[x_{n+h-1}] + \text{Var}[\varepsilon_{n+h}] + \theta^2 \text{Var}[\varepsilon_{n+h-1}] + \phi \theta \text{cov}_n(x_{n+h-1}, \varepsilon_{n+h-1})$
  - $= \phi^2 \sigma_{n+h-1|n}^2 + (1 + \theta^2 + \phi \theta) \sigma_\varepsilon^2$



## Modelo ARMA(p,q) - Caso Geral

$$x_t = \alpha + \phi_1 x_{t-1} + \cdots + \phi_p x_{t-p} + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \cdots + \theta_q \varepsilon_{t-q}$$

em que  $\alpha = (1 - \phi_1 - \cdots - \phi_p)\mu$  é o intercepto e  $\mu = E[x_t]$  é a média incondicional da série.

- Média condicional (Previsão Pontual)

$$\mu_{n+h|n} = \alpha + \phi_1 x_{n+h-1}^* + \cdots + \phi_p x_{n+h-p}^* + \theta_1 \varepsilon_{n+h-1}^* + \cdots + \theta_q \varepsilon_{n+h-q}^*$$

em que

$$x_j^* = \begin{cases} x_j, & j \leq n \\ \mu_{j|n}, & j > n \end{cases}$$

e

$$\varepsilon_j^* = \begin{cases} \varepsilon_j, & j \leq n \\ 0, & j > n \end{cases}$$

Desta forma, as previsões pontuais de qualquer modelo ARMA podem ser calculadas de forma recursiva para  $h = 1, 2, 3, \dots$

- Variância condicional - Modelo ARMA(p,q)

- Pro caso geral,  $\sigma_{n+h|n}^2$  é difícil de ser obtido diretamente.
- Vimos na Aula 7 que se verificada a condição de estacionariedade, então existe a representação do processo na forma causal, isto é, o processo pode ser escrito como um  $MA(\infty)$ .
- Digamos que essa representação seja dada por

$$x_t - \mu = \sum_{i=1}^{\infty} \psi_i \varepsilon_{t-i}$$

em que  $\psi_1, \psi_2, \psi_3, \dots$  são os coeficientes calculados do  $MA(\infty)$  (veja aula 7).

- Logo, o erro quadrático de previsão é obtido do processo  $MA(\infty)$

$$\sigma_{n+h|n}^2 = \left( 1 + \sum_{i=1}^{h-1} \psi_i^2 \right) \sigma_{\varepsilon}^2$$

## Exemplo

Exemplo: Suponha o modelo  $x_t = 0.4x_{t-1} + 0.3x_{t-2} + \varepsilon_t$  com  $\{\varepsilon_t\}$  sendo i.i.d  $N(0, 2)$ , foi identificado como sendo o mais adequado para uma série temporal terminada nos pontos  $x_{n-1} = 6.7$ ,  $x_n = 5$ . Determine a previsão pontual para cinco pontos a frente de  $n$ , calcule o erro quadrático de previsão e calcule a previsão intervalar com 95% de confiança.

- Previsão pontual:

$$\hat{x}_{n+1} = 0.4x_n + 0.3x_{n-1} = 0.4 \times 5 + 0.3 \times 6.7 = 4.01$$

$$\hat{x}_{n+2} = 0.4\hat{x}_{n+1} + 0.3x_n = 0.4 \times 4.01 + 0.3 \times 5 = 3.10$$

$$\hat{x}_{n+3} = 0.4\hat{x}_{n+2} + 0.3\hat{x}_{n+1} = 0.4 \times 3.10 + 0.3 \times 4.01 = 2.44$$

$$\hat{x}_{n+4} = 0.4\hat{x}_{n+3} + 0.3\hat{x}_{n+2} = 0.4 \times 2.44 + 0.3 \times 3.10 = 1.91$$

$$\hat{x}_{n+5} = 0.4\hat{x}_{n+4} + 0.3\hat{x}_{n+3} = 0.4 \times 1.91 + 0.3 \times 2.44 = 1.50$$

- coeficientes da forma causal (aula 6.2 e aula 7):  $\psi_i = \theta_i + \sum_{j=1}^i \phi_j \psi_{i-j}$ , com  $\psi_0 = 1$

$$\psi_1 = \phi_1 \psi_0 = 0.4 \times 1 = 0.4$$

$$\psi_2 = \phi_1 \psi_1 + \phi_2 \psi_0 = 0.4 \times 0.4 + 0.3 \times 1 = 0.46$$

$$\psi_3 = \phi_1 \psi_2 + \phi_2 \psi_1 + \phi_3 \psi_0 = 0.4 \times 0.46 + 0.3 \times 0.4 + 0 \times 1 = 0.304$$

$$\psi_4 = \phi_1 \psi_3 + \phi_2 \psi_2 + \phi_3 \psi_1 + \phi_4 \psi_0 = 0.2596$$

- erro quadrático de previsão:  $\sigma_{n+h|n}^2 = \left(1 + \sum_{j=1}^{h-1} \psi_j^2\right) \sigma_\varepsilon^2$

$$\sigma_{n+1|n}^2 = \sigma_\varepsilon^2 = 2$$

$$\sigma_{n+2|n}^2 = (1 + \psi_1^2) \sigma_\varepsilon^2 = 2.32$$

$$\sigma_{n+3|n}^2 = (1 + \psi_1^2 + \psi_2^2) \sigma_\varepsilon^2 = 2.743$$

$$\sigma_{n+4|n}^2 = (1 + \psi_1^2 + \psi_2^2 + \psi_3^2) \sigma_\varepsilon^2 = 2.928$$

$$\sigma_{n+5|n}^2 = (1 + \psi_1^2 + \psi_2^2 + \psi_3^2 + \psi_4^2) \sigma_\varepsilon^2 = 3.063$$

- previsão intervalar:  $(\mu_{n+h|n} - 1, 96 \sqrt{\sigma_{n+h|n}^2}, \mu_{n+h|n} + 1, 96 \sqrt{\sigma_{n+h|n}^2})$

$$(LI_{n+1}, LS_{n+1}) = (1.238, 6.781)$$

$$(LI_{n+2}, LS_{n+2}) = (0.120, 6.079)$$

$$(LI_{n+3}, LS_{n+3}) = (-0.803, 5.683)$$

$$(LI_{n+4}, LS_{n+4}) = (-1.445, 5.265)$$

$$(LI_{n+5}, LS_{n+5}) = (-1.928, 4.928)$$

## Section 3

### Previsão em modelos integrados

## Previsão Pontual em Modelos Integrados

- Previsão Pontual: consiste basicamente em tomar o inverso das transformações de diferença que levaram ao modelo estacionário.

- Exemplo: Modelo ARIMA(p,1,q)

Se  $\{x_t\}$  é um processo ARIMA(p,1,q), então a série  $\{w_t\}$ , dada por

$$w_t = \nabla x_t = x_t - x_{t-1}, \quad t = 2, 3, \dots, n$$

é um processo ARMA(p,q).

Logo se  $\hat{w}_{n+1|n}, \hat{w}_{n+2|n}, \dots, \hat{w}_{n+h|n}$  são as previsões pontuais de  $\{w_t\}$ , então as previsões de  $\{x_t\}$  são calculadas recursivamente tomando o inverso da diferença

$$\hat{x}_{n+1|n} = x_n + \hat{w}_{n+1|n}$$

$$\hat{x}_{n+2|n} = \hat{x}_{n+1|n} + \hat{w}_{n+2|n} = x_n + \hat{w}_{n+1|n} + \hat{w}_{n+2|n}$$

$$\vdots$$

$$\hat{x}_{n+h|n} = \hat{x}_{n+h-1|n} + \hat{w}_{n+h|n} = x_n + \sum_{i=1}^h \hat{w}_{n+i|n}$$

## Previsão Pontual em Modelos Integrados

- Obs 1: No caso de diferenças de ordens maiores,  $d > 1$ , a inversão deve ser feita recursivamente para  $d = 1, d = 2, \dots$
- Obs 2: O mesmo procedimento se aplica aos modelos sazonais.

## Exemplo:

Exemplo: Considere que o modelo  $\text{SARIMA}(1,1,1) \times (1,0,0)_6$ , com parâmetros  $\phi = 0.5$ ,  $\varphi = 0.7$  e  $\theta = 0.3$  foi identificado como sendo o mais adequado para uma determinada série temporal  $\{x_t\}$ , em que as ultimas 7 observações foram 100, 105, 109, 103, 95, 90, 96 e o ultimo resíduo  $\varepsilon_n = -5$ . Calcule a previsão pontual para os próximos 12 pontos.

- Modelo estacionário:  $w_t = (1 - B)x_t$  é  $\text{SARIMA}(1,0,1) \times (1,0,0)_6$ , ou seja,

$$w_t = 0.5w_{t-1} + 0.7w_{t-6} + \epsilon_t + 0.3\epsilon_{t-1}$$

- Carregando os dados no R e preparando os vetores

```
( x <- c(100,105,109,103,95,90,96,rep(NA,12)) )
```

```
## [1] 100 105 109 103 95 90 96 NA NA NA NA NA NA NA NA NA NA NA NA
```

```
( w <- c(NA, diff(x)) )
```

```
## [1] NA 5 4 -6 -8 -5 6 NA NA NA NA NA NA NA NA NA NA NA NA
```

```
( e <- c(rep(NA,6),-5,rep(0,12)) )
```

```
## [1] NA NA NA NA NA NA -5 0 0 0 0 0 0 0 0 0 0 0 0 0
```

```
( n <- 7 )
```

```
## [1] 7
```



- Previsão do  $w$

```
for(h in 1:12){  
  w[n+h] = 0.5*w[n+h-1] + 0.7*w[n+h-6] + e[n+h] + 0.3*e[n+h-1]  
}  
w %>% tail(12) %>% round(2)
```

```
## [1] 5.00 5.30 -1.55 -6.37 -6.69 0.86 3.93 5.67 1.75 -3.59 -6.47 -2.64
```

- Previsão do  $x$

```
for(h in 1:12){  
  x[n+h] = x[n+h-1] + w[n+h]  
}  
x %>% tail(12) %>% round(2)
```

```
## [1] 101.00 106.30 104.75 98.38 91.69 92.54 96.47 102.15 103.90 100.31  
## [11] 93.84 91.20
```

## Previsão Intervalar em Modelos Integrados

- Previsão Intervalar:

- O erro quadrático de previsão de 1-passo para qualquer modelo arima é  $\sigma_\varepsilon^2$ , pois

$$\sigma_{n+1|n}^2 = E_n[(x_{n+1} - \hat{x}_{n+1|n})^2] = E[\varepsilon_{n+1}^2] = \sigma_\varepsilon^2$$

- Para horizontes maiores, o calculo não é direto.
- Brockwell & Davis (1996), cap 6.5, demonstra sob certas hipóteses, para  $n$  suficientemente grande, o seguinte resultado

$$\sigma_{n+h|n}^2 = \sum_{j=0}^{h-1} \psi_j^2 \sigma_\varepsilon^2$$

em que  $\psi_0, \psi_1, \dots, \psi_{h-1}$  são os primeiros  $h - 1$  coeficientes do polinômio de médias móveis de ordem infinita, dado por,

$$\Psi(\beta) = \sum_{i=0}^{\infty} \psi_i \beta^i = \frac{\Theta_Q(B^s) \Theta_q(B)}{\Phi_P(B^s) \Phi_p(B) (1 - B^s)^D (1 - B)^d}$$

- A demonstração é controversa, pois implica que mesmo um modelo integrado ( $d \geq 1$  ou  $D \geq 1$ , não estacionário por definição) ainda poderia ser representado na forma de causal, isto é, como um MA( $\infty$ ) (estacionário).
- Desta forma, sob a hipótese de normalidade da componente de erro, a previsão intervalar pode ser calculada analiticamente (slide 1).

## Exemplo

Exemplo: Determine a equação dos erros quadráticos de previsão do ARIMA(1,1,1).

- Modelo:  $(1 - \phi B)(1 - B)x_t = (1 + \theta B)\varepsilon_t \Rightarrow x_t = \frac{(1 + \theta B)}{1 - (1 + \phi)B + \phi B^2} \varepsilon_t$
- De Brockwell & Davis, segue que:  $\frac{(1 + \theta B)}{1 - (1 + \phi)B + \phi B^2} = 1 + \psi_1 B + \psi_2 B^2 + \psi_3 B^3 + \psi_4 B^4 \dots$
- Então

$$\begin{aligned}
 1 + \theta B &= [1 - (1 + \phi)B + \phi B^2](1 + \psi_1 B + \psi_2 B^2 + \psi_3 B^3 + \psi_4 B^4 \dots) \\
 \Rightarrow 1 + \theta B &= 1 + \psi_1 B + \psi_2 B^2 + \psi_3 B^3 + \psi_4 B^4 \dots \\
 &\quad - (1 + \phi)B - (1 + \phi)\psi_1 B^2 - (1 + \phi)\psi_2 B^3 - (1 + \phi)\psi_3 B^4 + \dots \\
 &\quad + \phi B^2 + \phi\psi_1 B^3 + \phi\psi_2 B^4 + \dots \\
 \Rightarrow 0 &= B[\psi_1 - \theta - (1 + \phi)] + B^2[\psi_2 - (1 + \phi)\psi_1 - \phi] + B^3[\psi_3 - (1 + \phi)\psi_2 + \phi\psi_1] \\
 &\quad + B^4[\psi_4 - (1 + \phi)\psi_3 + \phi\psi_2] + B^5[\psi_5 - (1 + \phi)\psi_4 + \phi\psi_3] + \dots
 \end{aligned}$$

- Logo,  $\psi_0 = 1$ ,  $\psi_1 = \theta + 1 + \phi$  e os demais  $\psi_j = (1 + \phi)\psi_{j-1} - \phi\psi_{j-2}$ ,  $j = 2, 3, 4, \dots$
- E portanto,  $\sigma_{n+1|n}^2 = \sigma_\varepsilon^2$ ,  $\sigma_{n+2|n}^2 = (1 + \psi_1^2)\sigma_\varepsilon^2$ ,  $\sigma_{n+3|n}^2 = (1 + \psi_1^2 + \psi_2^2)\sigma_\varepsilon^2$ ,  $\sigma_{n+4|n}^2 = (1 + \psi_1^2 + \psi_2^2 + \psi_3^2)\sigma_\varepsilon^2$ ,  $\dots$

## Algumas considerações sobre previsão intervalar

- Previsões intervalares como vistas aqui tendem a ser mais afuniladas do que o real, isto ocorre devido as suposições que os parâmetros ajustados são os parâmetros verdadeiros e que a distribuição do termo de erro é Normal.
- Alternativamente, intervalos de confiança podem ser calculados via procedimentos de simulação conhecidos como Bootstrap.
  - Flexibiliza a escolha da distribuição de probabilidade do termo de erro.
  - Algumas abordagens permitem incluir a variabilidade do estimador no cálculo da previsão intervalar. Essas são conhecidas como Bootstrap Aggregating (Bagging).

## Section 4

### Previsão de modelos ARIMA utilizando o R

## Previsão de modelos ARIMA utilizando o R


- O R disponibiliza de forma nativa a função *predict()* que permite fazer previsões de modelos ARIMA.
  - Exemplo: na aula 10 identificamos o modelo SARIMA(1,1,0)×(0,1,0) como sendo adequado para a série AirPassengers do R.

```
fit <- arima(AirPassengers, order=c(1,1,0), seasonal = c(0,1,0))
fit %>% predict(n.ahead=12) ## um ano de previsão
```

```
## $pred
##           Jan           Feb           Mar           Apr           May           Jun           Jul           Aug
## 1961 444.3076 418.2130 446.2421 488.2331 499.2359 562.2351 649.2353 633.2352
##           Sep           Oct           Nov           Dec
## 1961 535.2353 488.2352 417.2353 459.2352
##
## $se
##           Jan           Feb           Mar           Apr           May           Jun           Jul           Aug
## 1961 11.70537 14.23728 16.95777 19.13818 21.13870 22.95303 24.63769 26.21327
##           Sep           Oct           Nov           Dec
## 1961 27.69968 29.11020 30.45549 31.74380
```

- O pacote *forecast* permite calcular previsão intervalar e fazer gráficos

```
require(forecast)  
fit %>% forecast(h=12, level=95) %>% plot()
```



- O pacote *forecast* também disponibiliza uma heurística ajustar automaticamente modelos da família ARIMA. Comando: *auto.arima()*

```
fit <- auto.arima(AirPassengers)
fit %>% forecast(h=12, level=95) %>% plot()
```

