

# Modelo linear de Holt e modelo Holt+Damped

## Análise de Séries Temporais

José Augusto Fiorucci

# Aula anterior

- Modelo SES( $\ell_0, \alpha$ ), com  $\ell_0 \in \mathbb{R}$  e  $\alpha \in (0, 1)$

- Equação original

$$\hat{y}_{t+1} = \alpha y_t + \alpha(1-\alpha)y_{t-1} + \alpha(1-\alpha)^2 y_{t-2} + \alpha(1-\alpha)^3 y_{t-3} + \dots$$

ou equivalentemente,

$$\hat{y}_{t+1} = \alpha y_t + (1-\alpha)\hat{y}_t$$

ou ainda,

$$\text{Previsão: } \hat{y}_t = \ell_{t-1}$$

$$\text{Level: } \ell_t = \alpha y_t + (1-\alpha)\ell_{t-1}$$

- Modelo Estocástico com erros aditivos ( $y_t = \mu_t + \varepsilon_t$ )

$$y_t = \ell_{t-1} + \varepsilon_t$$

$$\ell_t = \alpha y_t + (1-\alpha)\ell_{t-1}$$

- Representação em MEE

$$y_t = \ell_{t-1} + \varepsilon_t$$

$$\ell_t = \ell_{t-1} + \alpha \varepsilon_t$$

# Aula anterior

- Previsão  $\text{SES}(\ell_0, \alpha)$

$$\hat{y}_{n+h|n} = E_n[y_{n+h}] = \ell_n, \quad h = 1, 2, 3, \dots$$

com

$$\sigma_{n+h|n}^2 = \text{Var}_n[y_{n+h}] = \sigma_\varepsilon^2 + \alpha^2 \sigma_\varepsilon^2 (h - 1), \quad h = 1, 2, 3, \dots$$

## Section 1

# Método de Holt

# Método linear de Holt

Holt (1953) incluiu um termo de tendência ao método SES, para que a previsão fosse corrigida pela tendência, isto é

$$\hat{y}_{n+h|n} = E_n[y_{n+h}] = \ell_n + b_n h, \quad h = 1, 2, 3, \dots$$

em que  $b_t$  é o termo de crescimento (ou decrescimento), obtido a partir de um alisamento exponencial da variação dos níveis passados.

- Método de Holt:

$$\text{Previsão: } \hat{y}_t = \ell_{t-1} + b_{t-1}$$

$$\text{Level: } \ell_t = \alpha y_t + (1 - \alpha)(\ell_{t-1} + b_{t-1})$$

$$\text{Crescimento: } b_t = \beta^* (\ell_t - \ell_{t-1}) + (1 - \beta^*) b_{t-1}$$

Note que  $\beta^*$  é um parâmetro de alisamento, e portanto,  $\beta^* \in (0, 1)$ .

Admitindo erros aditivos ( $y_t = \mu_t + \varepsilon_t$ ), o método de Holt corresponde ao seguinte modelo estocástico

$$y_t = \ell_{t-1} + b_{t-1} + \varepsilon_t$$

$$\ell_t = \alpha y_t + (1 - \alpha)(\ell_{t-1} + b_{t-1})$$

$$b_t = \beta^* (\ell_t - \ell_{t-1}) + (1 - \beta^*) b_{t-1}$$

- Note que a segunda equação pode ser reescrita em função da componente estocástica

$$\ell_t = \ell_{t-1} + b_{t-1} + \alpha (y_t - \ell_{t-1} - b_{t-1}) \Rightarrow \ell_t = \ell_{t-1} + b_{t-1} + \alpha \varepsilon_t$$

da mesma forma, também podemos reescrever a terceira equação

$$b_t = b_{t-1} + \beta^* (\ell_t - \ell_{t-1} - b_{t-1}) \Rightarrow b_t = b_{t-1} + \alpha \beta^* \varepsilon_t$$

Assim obtemos a representação do modelo de Holt como MEE linear

$$y_t = \ell_{t-1} + b_{t-1} + \varepsilon_t$$

$$\ell_t = \ell_{t-1} + b_{t-1} + \alpha \varepsilon_t$$

$$b_t = b_{t-1} + \beta \varepsilon_t$$

em que  $\beta = \alpha \beta^*$ . Observe que os parâmetros do modelo são  $\ell_0 \in \mathbb{R}$ ,  $b_0 \in \mathbb{R}$ ,  $\alpha \in (0, 1)$  e  $\beta \in (0, \alpha)$ .

- Note que a correspondência com a equação de MEE linear que vimos na aula anterior é direta, basta tomarmos  $\mathbf{x}_t = (\ell_t, b_t)'$  como o vetor de espaço de estado, e reescrevermos as últimas equações em uma forma matricial

$$y_t = \begin{pmatrix} 1 & 1 \end{pmatrix} \mathbf{x}_{t-1} + \varepsilon_t$$

$$\mathbf{x}_t = \begin{pmatrix} 1 & 1 \\ 0 & 1 \end{pmatrix} \mathbf{x}_{t-1} + \begin{pmatrix} \alpha \\ \beta \end{pmatrix} \varepsilon_t$$

- Lembrete: MEE linear: 
$$\begin{cases} y_t = \mathbf{w}' \mathbf{x}_{t-1} + \varepsilon_t \\ \mathbf{x}_t = \mathbf{F} \mathbf{x}_{t-1} + \mathbf{g} \varepsilon_t \end{cases}$$

# Previsão do modelo de Holt

Note que

$$\begin{aligned}
 y_{n+h} &= \ell_{n+h-1} + b_{n+h-1} + \varepsilon_{n+h} \\
 &= (\ell_{n+h-2} + b_{n+h-2} + \alpha \varepsilon_{n+h-1}) + (b_{n+h-2} + \beta \varepsilon_{n+h-1}) + \varepsilon_{n+h} \\
 &= \ell_{n+h-2} + 2 b_{n+h-2} + (\alpha + \beta) \varepsilon_{n+h-1} + \varepsilon_{n+h} \\
 &= (\ell_{n+h-3} + b_{n+h-3} + \alpha \varepsilon_{n+h-2}) + 2 (b_{n+h-3} + \beta \varepsilon_{n+h-2}) + (\alpha + \beta) \varepsilon_{n+h-1} + \varepsilon_{n+h} \\
 &= \ell_{n+h-3} + 3 b_{n+h-3} + (\alpha + 2\beta) \varepsilon_{n+h-2} + (\alpha + \beta) \varepsilon_{n+h-1} + \varepsilon_{n+h} \\
 &\vdots \\
 &= \ell_n + h b_n + \sum_{i=1}^{h-1} (\alpha + i\beta) \varepsilon_{n+h-i} + \varepsilon_{n+h}
 \end{aligned}$$



Como

$$y_{n+h} = \ell_n + h b_n + \sum_{i=1}^{h-1} (\alpha + i\beta) \varepsilon_{n+h-i} + \varepsilon_{n+h}$$

segue que

- Previsão pontual:

$$\hat{y}_{n+h|n} = E_n[y_{n+h}] = \ell_n + h b_n, \quad h = 1, 2, 3, \dots$$

- Note que essas previsões são sempre lineares.

- Variância:

$$\sigma_{n+h|n}^2 = \text{Var}_n[y_{n+h}] = \left[ 1 + \sum_{i=1}^{h-1} (\alpha + i\beta)^2 \right] \sigma_\varepsilon^2$$

# Exercício

- Exercício 1: Suponha que as medianas das notas finais dos alunos que cursaram uma determinada disciplina nos ultimos 5 anos foram 4.7; 5.3; 4.6; 5.0; 4.5. Utilizando  $\alpha = 0.6$ ,  $\beta = 0.2$ ,  $\ell_0 = y_1$ ,  $b_0 = 0$ , calcule a previsão pontual e o erro quadrático médio de previsão do modelo Holt para os próximos 3 anos. Utilize o estimador usual para a variância do termo aleatório,  $\hat{\sigma}_\varepsilon^2 = \frac{1}{n} \sum_{t=1}^n \varepsilon_t^2$ .


-Resposta:

- Previsão pontual: 4.631, 4.574, 4.516
- Variância da previsão: 0.189, 0.310, 0.499

## R

- No R, utilize o comando *holt()* da biblioteca *forecast*.
- Exemplo:

```
holt(x, h=10) %>% plot()
```



# Modelo SES com drift

## Modelo SES com drift

- Um caso especial do modelo de Holt ocorre quando fixamos  $\beta = 0$ . Neste caso, a componente de crescimento se torna constante, pois  $b_t = b_0$ , para todo  $t = 1, 2, 3, \dots$ . Desta forma  $b_0$  corresponderá a uma taxa de crescimento fixa, geralmente chamada de *drift*.
- O modelo correspondente pode ser escrito como

$$y_t = \ell_{t-1} + b_0 + \varepsilon_t$$

$$\ell_t = \ell_{t-1} + b_0 + \alpha \varepsilon_t$$

o qual é conhecido como *SES com drift*.

- Curiosidade:

- Assimakopoulos & Nikolopoulos publicaram um artigo no *International Journal of Forecasting* descrevendo um algoritmo de previsão que eles chamaram de método Theta, o qual havia vendido a competição de previsão de séries temporais M3 (Makridakis 3), ocorrida no mesmo ano.
- Em 2003, Hyndman & Billah publicaram um artigo no mesmo periódico, o qual demonstra que o método Theta esta diretamente relacionado ao modelo *SES com drift*.
- O modelo DOTM (*Dynamic Optimized Theta Model*), proposto em Fiorucci et al (2016), possui a melhor performance já publicado para o banco de dados da M3, este consiste em uma evolução do método Theta. O modelo DOTM esta disponível no pacote *forecTheta* do R.

## Section 2

# Holt+Damped

# Método com tendência damped


- Proposto por Gardner e Mckenzie (1985)
- Modifica o método linear de Holt para possibilitar previsões com tendência amortizada, chama de “damping”
- Previsões com tendência damping

$$\hat{y}_{n+h|n} = \ell_n + (\phi + \phi^2 + \phi^3 + \dots + \phi^h) b_n$$

em que  $\phi \in (0, 1)$  é o parâmetro de damping.

- Note que
  - Se  $\phi = 0$ , as previsões coincidem com SES (previsões constantes)
  - Se  $\phi = 1$ , as previsões coincidem com Holt (previsões lineares)
  - Se  $0 < \phi < 1$ , então  $0 < \phi + \phi^2 + \phi^3 + \dots + \phi^h < h$  para qualquer  $h = 1, 2, 3, \dots$ , ou seja, as previsões tem tendência amortizadas.

- Exemplo: considerando  $\ell_n = 2$  e  $b_n = 0.5$ , cada linha da figura abaixo corresponde a previsão pontual construída variando  $\phi$  nos seguintes valores 0, 0.5, 0.75, 0.9 e 1.





# Método de Holt+Damped

- No método de Holt, essa modificação foi feita multiplicando por  $\phi$  a componente de crescimento

$$\text{Previsão: } \hat{y}_t = \ell_{t-1} + \phi b_{t-1}$$

$$\text{Level: } \ell_t = \alpha y_t + (1 - \alpha)(\ell_{t-1} + \phi b_{t-1})$$

$$\text{Crescimento: } b_t = \beta^* (\ell_t - \ell_{t-1}) + (1 - \beta^*) \phi b_{t-1}$$

Note que  $\beta^*$  é um parâmetro de alisamento, e portanto,  $\beta^* \in (0, 1)$ .

Admitindo erros aditivos ( $y_t = \mu_t + \varepsilon_t$ ), é fácil ver que o método de Holt com Damped corresponde ao seguinte modelo MEE linear

$$\begin{aligned}y_t &= \ell_{t-1} + \phi b_{t-1} + \varepsilon_t \\ \ell_t &= \ell_{t-1} + \phi b_{t-1} + \alpha \varepsilon_t \\ b_t &= \phi b_{t-1} + \beta \varepsilon_t\end{aligned}$$

em que  $\beta = \alpha \beta^*$ . Observe que os parâmetros do modelo são  $\ell_0 \in \mathbb{R}$ ,  $b_0 \in \mathbb{R}$ ,  $\alpha \in (0, 1)$ ,  $\beta \in (0, \alpha)$  e  $\phi \in (0, 1)$ .

- ou equivalentemente, se  $\mathbf{x}_t = (\ell_t, b_t)'$ , podemos reescrever na forma matricial

$$\begin{aligned}y_t &= \begin{pmatrix} 1 & \phi \end{pmatrix} \mathbf{x}_t + \varepsilon_t \\ \mathbf{x}_t &= \begin{pmatrix} 1 & \phi \\ 0 & \phi \end{pmatrix} \mathbf{x}_{t-1} + \begin{pmatrix} \alpha \\ \beta \end{pmatrix} \varepsilon_t\end{aligned}$$

- Lembrete: MEE linear: 
$$\begin{cases} y_t = \mathbf{w}' \mathbf{x}_{t-1} + \varepsilon_t \\ \mathbf{x}_t = \mathbf{F} \mathbf{x}_{t-1} + \mathbf{g} \varepsilon_t \end{cases}$$

- Pode-se mostrar que a variância da previsão é dada por

$$\sigma_{n+h|n}^2 = \sigma_{\varepsilon}^2 \left\{ 1 + \alpha^2(h-1) + \frac{\beta\phi h}{(1-\phi)^2} [2\phi(1-\phi) + \beta\phi] \right. \\ \left. - \frac{\beta\phi(1-\phi^h)}{(1-\phi)^2(1-\phi^2)} [2\alpha(1-\phi^2) + \beta\phi(1+2\phi-\phi^h)] \right\}$$

Referência: Hyndman et al (2008)

# Exercícios

- Exercício 2: Mostre que

$$\hat{y}_{n+h|n} = \ell_n + (\phi + \phi^2 + \phi^3 + \cdots + \phi^h) b_n$$

- Exercício 3: Mostre que

$$\lim_{h \rightarrow \infty} \hat{y}_{n+h|n} = \ell_n + \frac{\phi}{1 - \phi} b_n$$

## R

- No R, utilize o comando `holt(damped=TRUE)` da biblioteca `forecast`.
- Exemplo:

```
holt(x, h=10, damped=TRUE) %>% plot()
```

