

# Análise de Séries Temporais: Sazonalidade múltipla e modelos avançados

Prof. Dr. José Augusto Fiorucci

Universidade de Brasília  
Departamento de Estatística

# Múltiplos ciclos sazonais

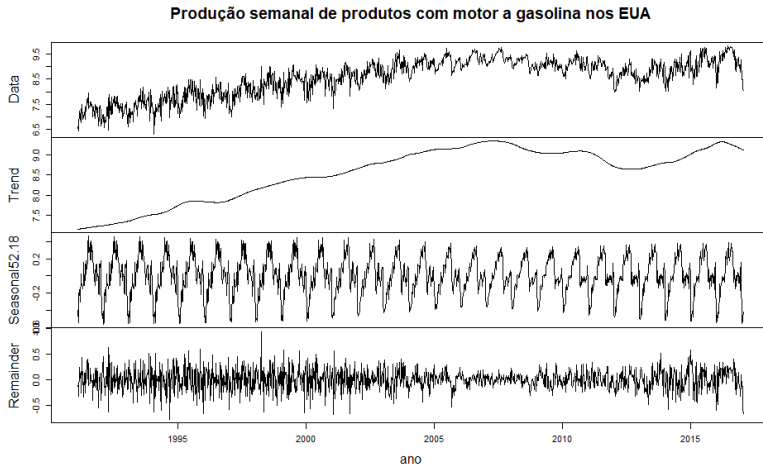
- Algumas séries possuem múltiplos ciclos sazonais que não são captados por modelos de alisamento exponencial convencionais, em especial, dados de frequência maior que mensal (também chamada de alta frequência):
  - Séries semanais usualmente apresentam ciclos sazonais mensal e anual
  - Séries diárias podem apresentar ciclos sazonais semanal, mensal e anual
  - Séries horárias podem apresentar ciclos sazonais diário, semanal, mensal e anual
- Estas também podem conter ciclos não inteiros (complexos)
  - Séries semanais possuem ciclo anual de  $365.25/7 = 52.17857$

# MSTL: decomposição STL com múltiplas sazonalidades

- Decomposição **STL**: Sazonalidade, Tendência e Loess
  - Referência: Cleveland, R. B., Cleveland, W. S., McRae, J. E., & Terpenning, I. J. (1990). STL: A seasonal-trend decomposition procedure based on loess. *Journal of Official Statistics*, 6(1), 3–33.
  - Vantagens em relação ao método clássico:
    - Tendência via Loess (regressão dinâmica)
    - Sazonalidade dinâmica
    - Usualmente fornece melhores resultados que a decomposição clássica
- Decomposição **MSTL**: STL com múltiplas sazonalidades
  - Faz múltiplas aplicações da decomposição STL
  - No pacote *forecast* do R, utilize `mstl()`;

# Exemplo: decomposição STL na série gasoline

```
> plot(mstl(gasoline))
```





# Exemplo call center - série com observações de 5 em 5 min

```
> plot(calls)
```

```
> plot(window(calls, end=4))
```

**Volume de ligações em um grande banco dos EUA (5 em 5 minutos)**





# Exemplo call center - decomposição MSTL

```
> y = window(calls, end=4)
```

```
> plot(mstl(y))
```


Volume de ligações em um grande banco dos EUA (5 em 5 minutos)



# Previsão via STL + ETS

- Função `stlf()`
  - Retira a sazonalidade via `MSTL`;
  - Faz previsão da série com sazonalidade ajustada utilizando `ETS`;
  - Inclui a sazonalidade do ultimo ciclo na previsão;
- Exemplo: (série call center)  

```
> plot( stlf(y, h=frequency(y)) ) # previsão de uma semana
```



# Modelo BATS

- Modelo BATS

B: transformação de **B**ox-cox para heterogeneidade

A: modelo **A**RNA para erros

T: **T**endência via alisamento exponencial

S: **S**azonalidade multipla via alisamento exponencial

- Referência:

De Livera, A. M., Hyndman, R. J., Snyder, R. D. (2011). Forecasting time series with complex seasonal patterns using exponential smoothing. Journal of the American Statistical Association, 106(496), 1513-1527.



# Modelo BATS

$y_t$  = série original no tempo  $t$

$$y_t^{(\omega)} = \begin{cases} (y_t^\omega - 1)/\omega & \text{se } \omega \neq 0 \\ \log y_t & \text{se } \omega = 0 \end{cases} \quad (\text{Transformação de Box-Cox})$$

$$y_t^{(\omega)} = \ell_{t-1} + \phi b_{t-1} + \sum_{i=1}^M s_{t-m_i}^{(i)} + e_t \quad (\text{HW+Damped})$$

$$\ell_t = \ell_{t-1} + \phi b_{t-1} + \alpha e_t$$

$$b_t = (1 - \phi)b + \phi b_{t-1} + \beta e_t$$

$$s_t^{(i)} = s_{t-m_i}^{(i)} + \gamma_i e_t$$

$$e_t = \sum_{i=1}^p \phi_i e_{t-i} + \sum_{j=1}^q \theta_j \varepsilon_{t-j} + \varepsilon_t \quad (\text{ARMA})$$

em que  $\omega$  é o parâmetro da transformação de Box-Cox,  $\gamma_1, \dots, \gamma_M$  são parâmetros de alisamento sazonal e  $m_1, m_2, \dots, m_M$  são os tamanhos dos ciclos sazonais.

# Decomposição em série harmônica (Séries de Fourier)

- Idéia: a sazonalidade pode ser vista como uma sobreposição de séries harmônicas (senos, cossenos) .
- Transformação de Fourier:


$$s_t = a_0 + a_1 \sin\left(\frac{2\pi t}{m}\right) + a_2 \cos\left(\frac{2\pi t}{m}\right) + a_3 \sin\left(\frac{4\pi t}{m}\right) + a_4 \cos\left(\frac{4\pi t}{m}\right) \\ + a_5 \sin\left(\frac{6\pi t}{m}\right) + a_6 \cos\left(\frac{6\pi t}{m}\right) + \dots$$

onde  $a_1, a_2, a_3, \dots$  são parâmetros e  $m$  é a frequência da série (ou ciclo sazonal);

- Permite que sazonalidades múltiplas sejam modeladas;
- Permite que ciclos não inteiros sejam modelados;


# Decomposição em série harmônica (Séries de Fourier)

- Exemplo:



# Decomposição em série harmônica (Séries de Fourier)

- Exemplo: combinando as 4 primeiras séries harmônicas



# Modelo TBATS

- Modelo TBATS

T: termos **T**rigonometricos para sazonalidade

B: transformação de **B**ox-cox para heterogeneidade

A: modelo **A**RMA para erros

T: **T**endência via alisamento exponencial (ETS)

S: **S**azonalidade multipla ou para períodos não inteiros

- Referência:

De Livera, A. M., Hyndman, R. J., Snyder, R. D. (2011). Forecasting time series with complex seasonal patterns using exponential smoothing. Journal of the American Statistical Association, 106(496), 1513-1527.

# Modelo TBATS

$y_t$  = série original no tempo  $t$

$$y_t^{(\omega)} = \begin{cases} (y_t^\omega - 1)/\omega & \text{se } \omega \neq 0 \\ \log y_t & \text{se } \omega = 0 \end{cases} \quad (\text{Transformação de Box-Cox})$$

$$y_t^{(\omega)} = \ell_{t-1} + \phi b_{t-1} + \sum_{i=1}^M s_{t-m_i}^{(i)} + e_t \quad (\text{HW+Damped})$$

$$\ell_t = \ell_{t-1} + \phi b_{t-1} + \alpha e_t$$

$$b_t = (1 - \phi)b + \phi b_{t-1} + \beta e_t$$

$$s_t^{(i)} = \sum_{j=1}^{k_i} s_{j,t}^{(i)} \quad (\text{Fourier})$$

$$s_{j,t}^{(i)} = s_{j,t-1}^{(i)} \cos \lambda_j^{(i)} + s_{j,t-1}^{*(i)} \sin \lambda_j^{(i)} + \gamma_1^{(i)} e_t$$

$$s_{j,t}^{*(i)} = -s_{j,t-1}^{(i)} \sin \lambda_j^{(i)} + s_{j,t-1}^{*(i)} \cos \lambda_j^{(i)} + \gamma_2^{(i)} e_t$$

$$e_t = \sum_{i=1}^p \phi_i e_{t-i} + \sum_{j=1}^q \theta_j e_{t-j} + \varepsilon_t \quad (\text{ARMA})$$

em que  $\lambda_j^{(i)} = 2\pi j/m_i$  e  $m_1, m_2, \dots, m_M$  são os tamanhos dos ciclos sazonais. O número de funções harmônicas requiridas para cada componente é denotado por  $k_i$ .

# Modelo TBATS


- Para detalhes sobre a componente sazonal, veja o livro:  
*West, M. Harrison, J. (1997), Bayesian forecasting and dynamic models, 2nd edn, Springer-Verlag, New York.*
- O modelo TBATS também pode ser escrito como um modelo de espaço de estado não linear;
- A verossimilhança é conhecida;
- Previsão pontual e intervalar podem ser feitos via bootstrap;
- Identificação da ordem do modelo:

$$\text{TBATS}(\omega, \{p, q\}, \phi, \{< m_1, k_1 >, < m_2, k_2 >, \dots, < m_M, k_M >\})$$

# Exemplo gasoline: decomposição

```
> fit = tbats(gasoline)
```

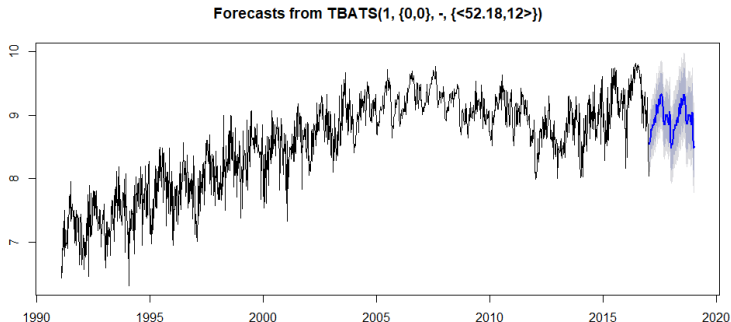
```
> plot(fit)
```





# Exemplo gasoline: previsão


```
> plot( forecast(fit, h=104) ) # dois anos de previsão (104 semanas)
```



# Exemplo call center: decomposição

```
> fit = tbats(y)
```

```
> plot(fit)
```



# Exemplo call center: previsão

```
> plot( forecast(fit,h=frequency(y)) ) # previsão de uma semana
```

