

# VaR - *Value at Risk*

Prof. Dr. José Augusto Fiorucci

Universidade de Brasília  
Departamento de Estatística

Seja  $x_1, \dots, x_n$  uma série financeira (Ex.: fechamento diário de uma ação)

- Retornos

$$y_t = (x_t - x_{t-1})/x_{t-1} = \frac{x_t}{x_{t-1}} - 1$$

- log-retornos (ou simplesmente retornos)

$$y_t = \log(x_t/x_{t-1}) = \nabla \log(x_t)$$

- Vimos que na prática a definição de retornos ou log-retornos se equivalem

$$\log(x_t/x_{t-1}) \approx (x_t - x_{t-1})/x_{t-1}$$

- Volatilidade

$$h_t = \text{Var}_{t-1}[y_t]$$

Obs: aqui nos referimos a volatilidade como sendo a variância condicional dos retornos, no entanto, alguns livros equivalentemente referem a volatilidade como sendo o desvio padrão condicional ( $\sqrt{h_t}$ ).

- A homocedasticidade (variância constante) de uma série de retornos pode ser testada aplicando o teste de independência de Ljung-Box em  $\{y_t^2\}$ . Assim, se o teste rejeita a hipótese nula, então a série é considerada heterocedástica.

- Modelo GARCH(p,q)

$$y_t = \sqrt{h_t} \varepsilon_t$$
$$h_t = \alpha_0 + \sum_{i=1}^p \alpha_i y_{t-i}^2 + \sum_{j=1}^q \beta_j h_{t-j}$$

sendo  $\{\varepsilon_t\}$  i.i.d  $N(0, 1)$  (ou outra distribuição padronizada);

- Quando os retornos apresentam autocorrelação ou média diferente de zero, pode-se utilizar primeiramente um modelo ARMA e depois o GARCH para os resíduos;

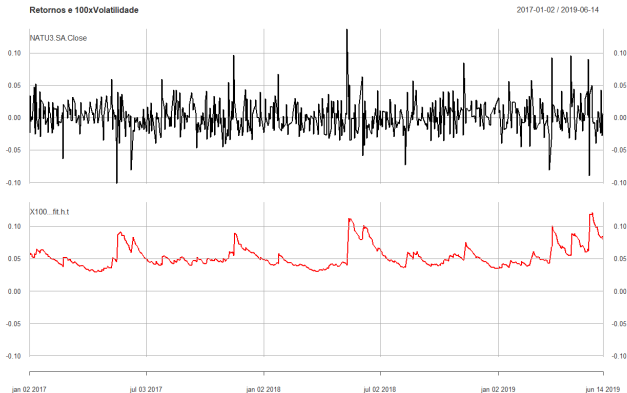
# Aulas anteriores

- Ajuste: código do R

```
> require(fGarch)
```

```
> fit = garchFit(formula = garch(1,1), data=y)
```

- Gráfico dos retornos e da volatilidade ( $\times 100$ )



# Value at Risk (VaR)

- A ideia básica do VaR é responder a seguinte pergunta:  
Em condições normais do mercado, qual a perda máxima esperada dentro de um horizonte de tempo e de uma probabilidade?
- Exemplo:  
Se um fundo de investimento afirma que o VaR de 95% da carteira deles é de R\$100.000,00, significa que só existe 5% de chance da carteira desvalorizar mais que R\$100.000,00 em um dia.
- OBS: catástrofes financeiras do tipo, delação do Joesley Batista, greve dos caminhoneiros, Brumadinho, entre outras, não são consideradas.

# Value at Risk (VaR)

- Na prática, o VaR pode ser entendido como uma proporção ou o capital (abordagem mais comum)
  - **percentual:** o VaR consiste no quantil da distribuição condicional dos retornos.
    - Exemplo: O VaR de 95% da ação PETR4 para amanhã é de 2%, ou seja, existe 95% de chance da carteira não perder mais que 2% do capital até amanhã.
  - **capital:** o VaR consiste no quantil da distribuição condicional dos retornos multiplicado pelo capital investido.
    - Exemplo: Suponha que no exemplo anterior a carteira possui hoje o capital de R\$ 10.000,00, assim podemos afirmar que o VaR de 95% é 2% de R\$10.000,00, ou seja,  $\text{VaR}(95\%) = \text{R\$}200,00$ .

- VaR para modelo GARCH

- Admitindo um modelo GARCH com erros normais para a série de retornos, isto é,

$$y_t = \sqrt{h_t} \varepsilon_t$$

em que  $\{\varepsilon_t\}$  é i.i.d.  $N(0, 1)$  com  $h_t$  sendo modelado pelo GARCH.

- Então

$$y_{t|t-1} \sim N(0, h_t)$$

- Portanto

$$VaR_t [(1 - \alpha)\%] = (-\sqrt{h_t} q_\alpha) C$$

em que  $q_\alpha$  é o quantil  $\alpha$  da  $N(0, 1)$  e  $C$  é o montante investido.

- OBS: Se outra distribuição de probabilidade é assumida para o termo de erro, então o quantil desta outra distribuição deve ser considerado para o cálculo do VaR;



- VaR para modelo ARMA-GARCH

- Admitindo um modelo ARMA-GARCH com erros normais para a série de retornos, isto é,

$$y_t = \mu_t + \sqrt{h_t} \varepsilon_t$$

em que  $\{\varepsilon_t\}$  é i.i.d.  $N(0, 1)$ , com  $\mu_t$  sendo modelado pelo ARMA e  $h_t$  sendo modelado pelo GARCH.

- Então

$$y_{t|t-1} \sim N(\mu_t, h_t)$$


- Portanto

$$\text{VaR}_t [(1 - \alpha)\%] = -(\sqrt{h_t} q_\alpha + \mu_t) C$$

em que  $q_\alpha$  é o quantil  $\alpha$  da  $N(0, 1)$  e  $C$  é o montante investido.

# Exemplo NATU3: Retornos e VaR(95%)

- Modelo GARCH(1, 1) com erros normais



# Volatilidade e VaR em períodos maiores

- Vimos em aulas anteriores que o log-retorno de um período maior corresponde a soma dos log-retornos dos períodos menores.

Exemplo

- Retorno para 2 dias

$$y_t^{(2)} = \log(x_t/x_{t-2}) = y_t + y_{t-1}$$

- Retorno para k dias

$$y_t^{(k)} = \log(x_t/x_{t-k}) = y_t + y_{t-1} + \cdots + y_{t-(k+1)}$$

em que  $\{y_t\}$  denota os log-retornos diários;

- Sob a suposição de não autocorrelação dos retornos, temos

- Volatilidade para 2 dias

$$\hat{h}_{t+2|t}^{(2)} = \hat{h}_{t+2|t} + \hat{h}_{t+1|t}$$

- Volatilidade para k dias

$$\hat{h}_{t+k|t}^{(k)} = \hat{h}_{t+k|t} + \hat{h}_{t+k-1|t} + \cdots + \hat{h}_{t+1|t}$$

# Aplicação: VaR para uma semana

- Suponha que deseja-se calcular o VaR para uma semana (5 dias úteis)
- Inicialmente calcule a previsão de volatilidade para os próximos 5 dias.

- Some as previsões para obter a volatilidade no período,

$$\hat{h}_{t+5|t}^{(5)} = \hat{h}_{t+5|t} + \hat{h}_{t+5-1|t} + \cdots + \hat{h}_{t+1|t}$$

- O VaR de  $(1 - \alpha)\%$  para uma semana é dado por

- Modelo GARCH

$$VaR_{t+5}[(1 - \alpha)\%]^{(5)} = - \left( \sqrt{\hat{h}_{t+5|t}^{(5)}} q_{\alpha} \right) C$$

- Modelo ARMA+GARCH

$$VaR_{t+5}[(1 - \alpha)\%]^{(5)} = - \left( \sqrt{\hat{h}_{t+5|t}^{(5)}} q_{\alpha} + \mu_{t+5|t} \right) C$$

## Exemplo:

- $VaR(95\%)$  para 1 e 5 dias via modelo GARCH(1,1) com erros  $N(0,1)$ .

Código do R

```
> h = predict(fit,n.ahead=5)[,3]^2  
> -qnorm(0.05,mean=0,sd=sqrt(h[1])) # 1 dia  
0.0474639  
> -qnorm(0.05,mean=0,sd=sqrt(sum(h))) # 5 dias  
0.1056352
```

- Interpretação:

- Com 95% de probabilidade, a perda máxima esperada para um dia é de 4,74% do capital investido;
- Com 95% de probabilidade, a perda máxima esperada para uma semana é de 10,56% do capital investido;

# VaR para uma carteira de ações

- Suponha que o investimento esteja dividido em mais de uma ação
- A técnica anterior permite calcular o VaR para cada ação individualmente
- Mas e para a carteira como um todo?

# VaR para uma carteira de ações

- Suponha que o capital  $C$  esteja distribuído em  $k$  ações com os seguintes pesos  $\mathbf{w} = (w_1, \dots, w_k)'$ ;
- Definimos o retorno na carteira como a soma dos retornos individuais ponderado pelos  $w$ 's, isto é,

$$y_t = \sum_{i=1}^k w_i y_{i,t}$$

em que  $y_{i,t} = \log(x_{i,t}/x_{i,t-1})$  é o retorno da  $i$ -ésima ação no momento  $t$ .

- Assim, a volatilidade da carteira é dada por

$$h_t = \sum_{i=1}^k w_i^2 h_{i,t} + \sum_{i,j=1, i \neq j}^k w_i w_j \text{Cov}_{t-1}(y_{i,t}, y_{j,t})$$

em que  $h_{i,t}$  denota a volatilidade da  $i$ -ésima ação no tempo  $t$ .

# VaR para uma carteira de ações

- Equivalente também podemos escrever a volatilidade da carteira no formato matricial

$$h_t = \mathbf{w}' H_t \mathbf{w}$$

em que  $H_t$  denota a matriz de auto-covariâncias condicional do retornos no tempo  $t$ .

- Obtida a volatilidade da carteira, o  $VaR[(1 - \alpha)\%]$  pode ser calculado da mesma forma que anteriormente, isto é,

$$VaR_t [(1 - \alpha)\%] = -(\sqrt{h_t} q_\alpha + \mu_t) C$$

- Logo, a única dificuldade gira em torno de se obter as auto-covariâncias condicionais;



## Exercício 1:

Suponha que na presente data, a sua carteira de investimento esteja distribuída como na tabela abaixo

Ativo	Custódia
PETR4	500
VALE3	300
BBAS3	250
<b>Total</b>	1050

- (a) Supondo covariância constante entre os retornos, obtenha uma aproximação para a matriz  $\mathbf{H}_t$ ;
- (b) Calcule o  $\text{VaR}[95\%]$  para o próximo dia;

# Modelo CCC-GARCH

- Seja  $\mathbf{y}_t = (y_{1,t}, \dots, y_{k,t})'$  é o vetor dos retornos no tempo  $t$
- CCC-GARCH: Constante Conditional Correlation GARCH

$$\mathbf{y}_t = H_t^{1/2} \boldsymbol{\epsilon}_t$$

$$H_t = D_t R D_t$$

$$D_t = \text{diag}(h_{1,t}^{1/2}, \dots, h_{k,t}^{1/2})$$

em que  $H_t^{1/2}$  denota a decomposição de Cholesky de  $H_t$  e  $R$  denota a matriz de correlação dos retornos, a qual é admitida ser constante por este modelo.

- Proposto em Bollerslev, T. 1990, Modelling the coherence in short-run nominal exchange rates: a multivariate generalized ARCH model, The Review of Economics and Statistics, 72(3), 498–505

# Modelo DCC-GARCH

- DCC-GARCH: Dynamic Conditional Correlation GARCH

$$\mathbf{y}_t = H_t^{1/2} \boldsymbol{\epsilon}_t$$

$$H_t = D_t R_t D_t$$

$$D_t = \text{diag}(h_{1,t}^{1/2}, \dots, h_{k,t}^{1/2})$$

$$R_t = \text{diag}(Q_t)^{-1/2} Q_t \text{diag}(Q_t)^{-1/2}$$

$$Q_t = (1 - a - b)R + a \mathbf{u}_{t-1} \mathbf{u}_{t-1}' + b Q_{t-1}$$

em que  $\mathbf{u}_t = D_t^{-1} \mathbf{y}_t$  são os retornos padronizados e  $R$  é a matriz de covariância incondicional de  $\mathbf{u}_t$ .  $Q_t$  pode ser interpretada como a matriz de covariância dos erros padronizados, e por ser modelada como um GARCH(1,1), temos  $a > 0$ ,  $b > 0$  e  $a + b < 1$ . Após alguma álgebra, pode-se demonstrar que  $h_{ij,t} = q_{ij,t} \sqrt{h_{ii,t} h_{jj,t}} / \sqrt{q_{ii,t} q_{jj,t}}$ .

- Proposto em Engle, R. F. (2002). Dynamic conditional correlation - a simple class of multivariate GARCH models. Journal of Business and Economic Statistics 20, 339-350.

# Implementações no R

- **Inferência clássica:**

pacotes: `ccgarch`, `rmgarch`

- **Inferência Bayesiana:**

Pacote: `bayesDccGarch`

Vantagens: considera a incerteza a respeito do estimador

Desvantagens: custo computacional

Referência:

Fiorucci, J. A., R. S. Ehlers, and M. G. Andrade (2014). Bayesian multivariate GARCH models with dynamic correlations and asymmetric error distributions. *Journal of Applied Statistics* 41 (2), 320-331.

## Exercício 2

Considerando a carteira de investimento abaixo, verifique o histórico do  $\text{VaR}[95\%]$  pelo modelo DCC-GARCH.

Ativo	Custódia
PETR4	500
VALE3	300
BBAS3	250
<b>Total</b>	1050